

# **Trabajo de Campo:**

## **Sistemas de Inferencia Difusa**

### **(Sugeno - Mamdani)**

#### **Introducción**

La lógica difusa ha revolucionado el campo de la inteligencia artificial y la toma de decisiones en situaciones donde la precisión y la certeza son difíciles de alcanzar. Dos de los enfoques más destacados en este ámbito son los sistemas de inferencia difusa de Sugeno y Mamdani. Estos sistemas, basados en principios matemáticos y de lógica difusa, permiten modelar y abordar problemas complejos en diversas áreas, desde el control de procesos industriales hasta la toma de decisiones en sistemas expertos. En este trabajo, hemos utilizado tanto el sistema de inferencia difusa de Sugeno como el de Mamdani, analizando sus características, aplicaciones y diferencias clave. Además, examinaremos ejemplos concretos de cómo estos sistemas pueden ser implementados para resolver problemas del mundo real.

#### **Sobremuestreo de señales VDA (Variación de Diámetro Arterial)**

Para esta tarea se utilizó el **Sistema de Inferencia Difusa de Sugeno** teniendo en cuenta que es un trabajo el cual requiere regresión para poder generar el sobremuestreo.

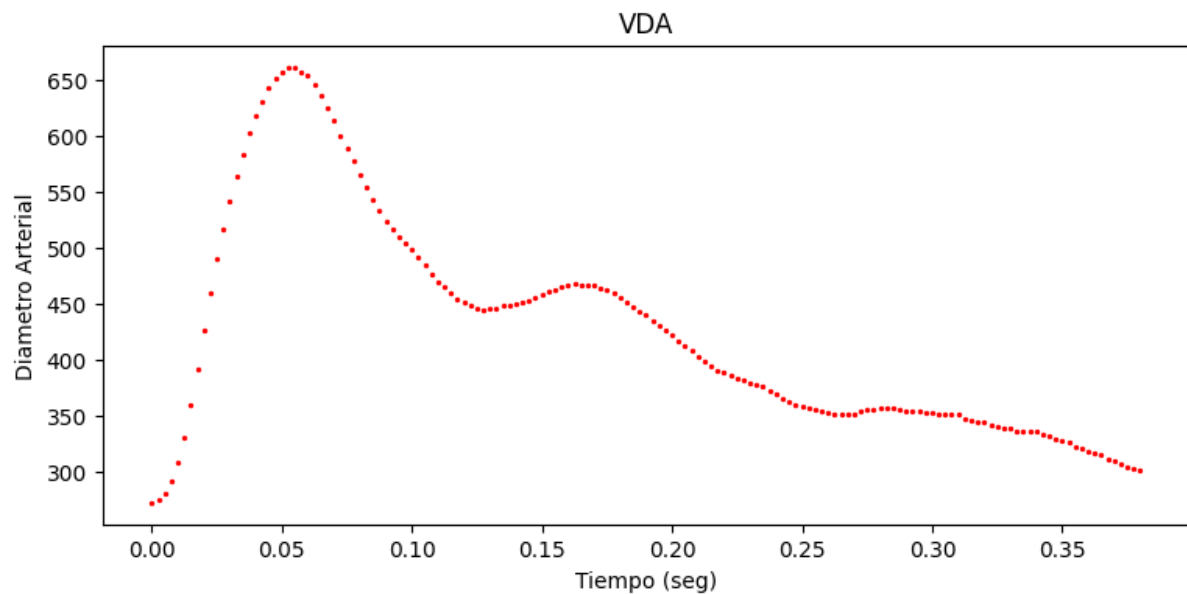
La regresión se implementó como se dijo con Sugeno y para generar las reglas al no tener targets se obtuvieron por medio de clustering sustractivo. El código de implementación fue proveído por la cátedra de la materia, lo mismo con los datos de VDA los cuales fueron tomados con una frecuencia de  $1/400 \text{ s} = 2.5\text{ms}$ .

Para entrenar al modelo lo que se hizo además de utilizar el entrenamiento ya implementado por el código se fue variando en cada iteración el radio de separación de los clusters. A medida que se fueron haciendo pruebas se llegó a la conclusión de que aplicando 80 iteraciones y variando mediante el cociente de la iteración entre 150 se llega a un fit bastante aceptable para la mayoría de muestras por lo cual se terminó manteniendo para los entrenamientos.



Al calcular el MSE hay un error de código el cual no se pudo resolver, sin embargo el modelo funciona y réplica bien los datos, por lo tanto no se ahondó en ese sentido y claramente sería algo a mejorar, modificando el error o implementar de cero el código que crea el modelo.

A continuación se analizará cada muestra por separado.


**Análisis de la muestra 1:**



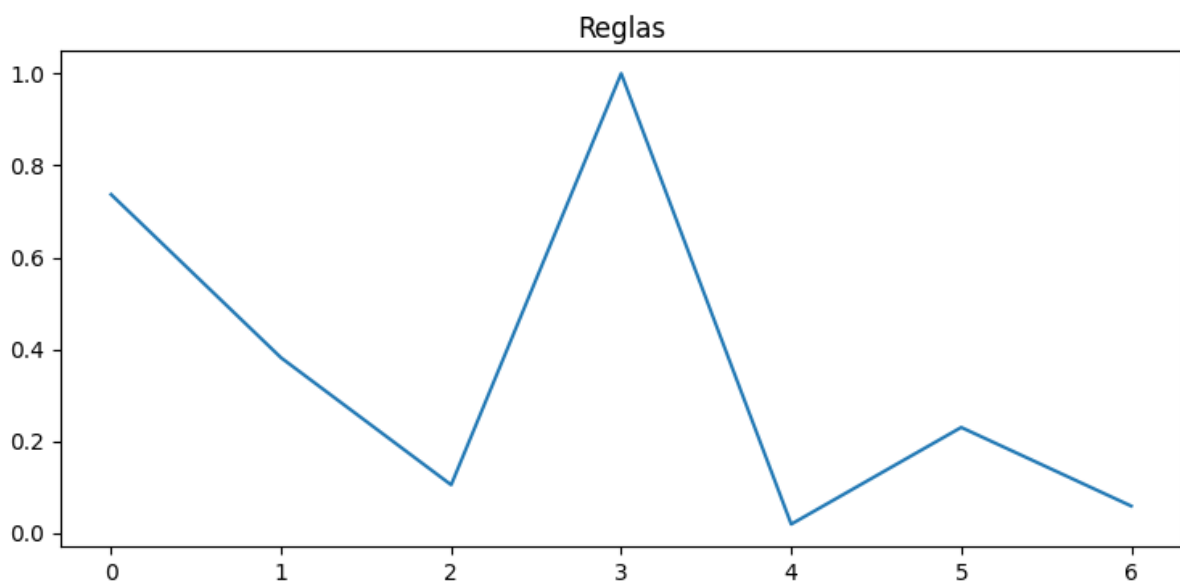
Arriba se muestran los datos sin normalizar, a continuación se encuentran los datos normalizados con las funciones de activación de los centros de cluster obtenidos.




A continuación se muestra el **modelo obtenido** (puntos rojos) **vs. muestra** (curva gris).




Se puede ver como el modelo es casi uniforme respecto de la muestra. Esto nos demuestra que el entrenamiento fue exitoso para este conjunto de datos



A continuación se muestra el MSE (Error Cuadrático Medio) de entrenamiento, que como se dijo anteriormente no está bien implementado por lo tanto no es de fiar. Sin embargo el error en las primeras iteraciones parece ser estable, hasta que genera un pico alrededor de la 60° iteración.

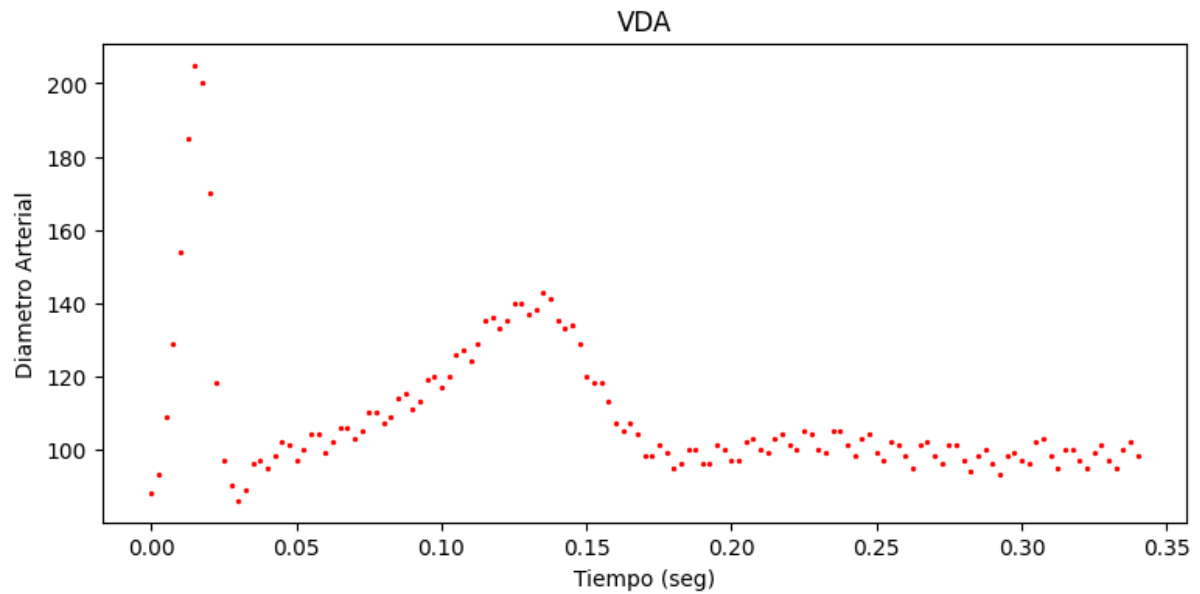


El resultado del sobremuestreo es el siguiente cuadro.






Se realizó sobremuestreo con números de  $[0,1]$  con paso 0,0001. Detrás en gris se puede ver la muestra. Como podemos ver el modelo quedó suficientemente uniforme lo que produjo un resultado aceptable.

### **Análisis de la muestra 2:**

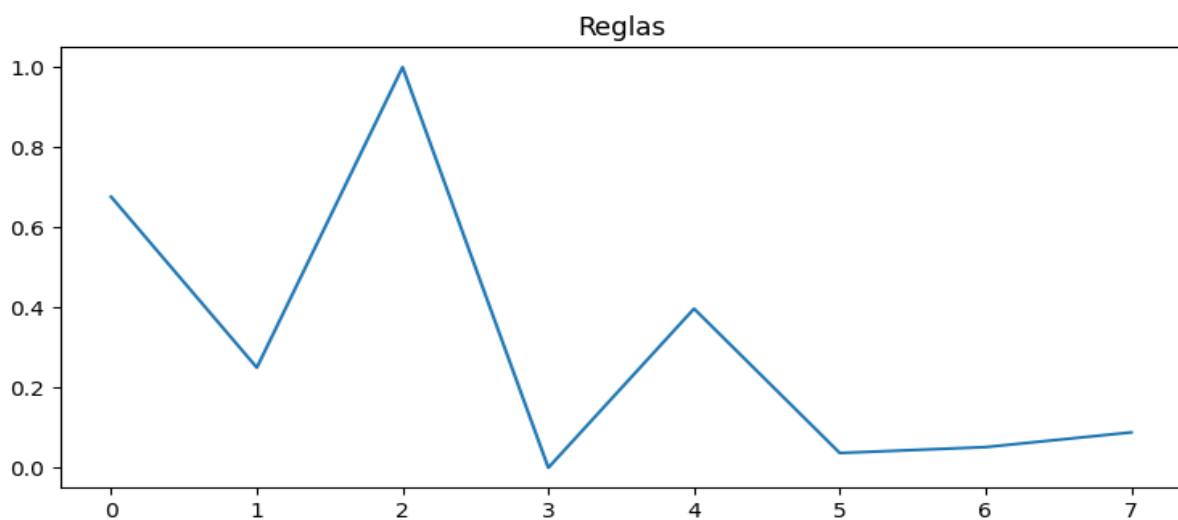


Como se puede ver la muestra es muy ruidosa, a continuación se muestra la muestra normalizada con sus funciones de activación de los centros de cluster.

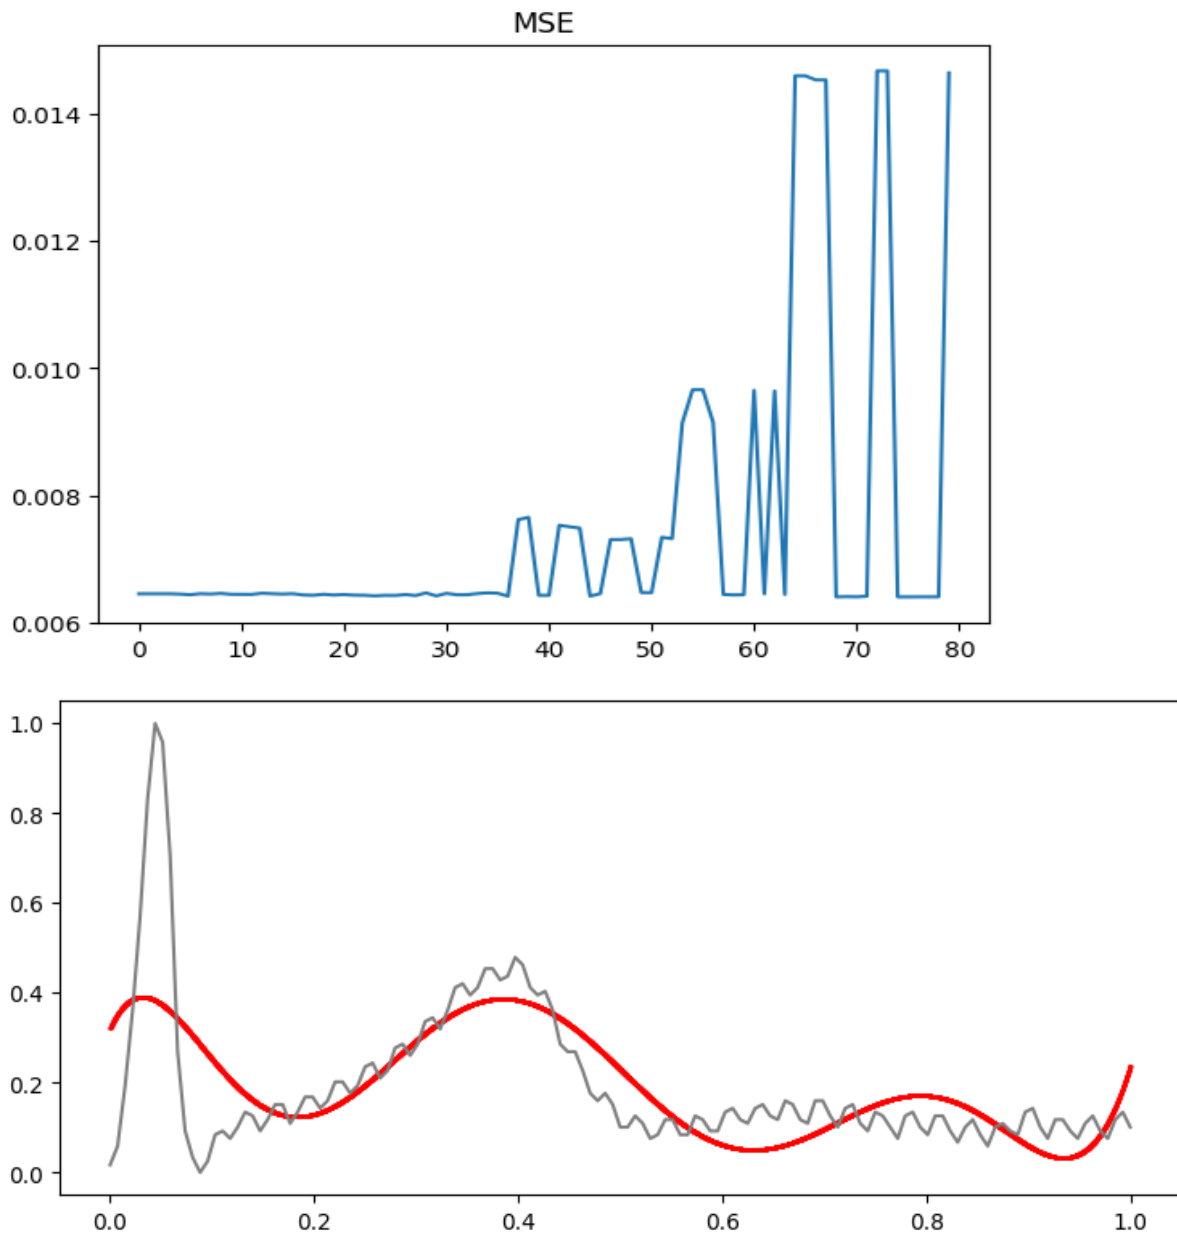




Como se puede ver el modelo generado es bastante deficiente, lo cual no nos permite hacer una buena regresión debido al ruido de la muestra.



Las reglas por el contrario parecen generalizar bastante bien teniendo en cuenta lo ruidosa que es la muestra.



Como se puede observar desde el tiempo 0,2 al 0,6 se trata de acomodar a pesar del ruido, pero igual sigue siendo un modelo que no sirve.

## Conclusiones

En resumen, en este trabajo se realizó un análisis detallado de dos muestras utilizando un modelo de regresión basado en clustering. A través de un proceso de entrenamiento iterativo y variando el radio de separación de los clusters, se logró obtener un ajuste aceptable para la mayoría de las muestras. A pesar de un error en el cálculo del Error Cuadrático Medio (MSE), se demostró que el modelo es capaz de replicar los datos de manera efectiva.

El análisis de la primera muestra reveló que el modelo se ajusta bien a los datos, demostrando el éxito del entrenamiento. Sin embargo, se reconoció la necesidad de mejorar la implementación del cálculo del MSE.

En contraste, la segunda muestra resultó ser más ruidosa, lo que dificulta la generación de un modelo de regresión eficaz. A pesar de esto, las reglas generadas por el modelo demostraron ser capaces de generalizar de manera adecuada, considerando la naturaleza ruidosa de la muestra.

En conclusión, este trabajo proporciona una visión general de la implementación y resultados de un modelo de regresión basado en clustering, destacando la importancia de la iteración y el ajuste del radio de separación de los clusters en el proceso de entrenamiento. Aunque se identificaron áreas de mejora, los resultados muestran un potencial prometedor para la aplicación de este enfoque en la regresión de datos en diferentes escenarios.

### **Automatización del trabajo de un calderista**

Para esta tarea se utilizó el **Sistema de Inferencia Difusa de Mamdani** teniendo en cuenta que el trabajo de un calderista requiere un modelo que utilice la lógica difusa.

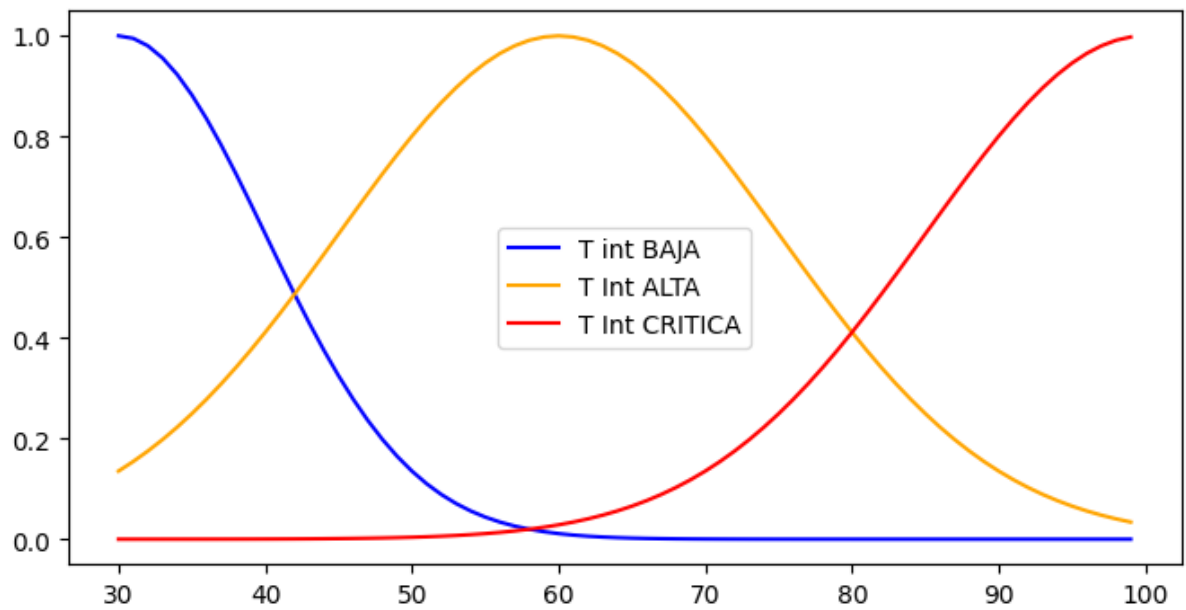

Las reglas que se utilizaron fueron:

1. Cuando la TEMPERATURA EXTERIOR es BAJA , la COMBUSTION debe ser ALTA.
2. Cuando la TEMPERATURA EXTERIOR es MEDIA, la COMBUSTION debe ser MODERADA
3. Cuando la TEMPERATURA EXTERIOR es ALTA, la COMBUSTION debe estar en PILOTO.
4. Cuando la TEMPERATURA INTERIOR sea ALTA, la COMBUSTION debe LIMITARSE LIGERAMENTE
5. Cuando la TEMPERATURA INTERIOR sea CRITICA, la COMBUSTION debe ser REDUCIDA

Para implementarlas en código se utilizó mínimos entre las variables de entrada y la variable de salida.


A continuación se muestran las funciones de membresía de las variables de entrada y salida. Las temperaturas son las del eje X en °C.





Se creó el rango de temperatura interna baja pero no se utiliza, es más para tener una especie de referencia de donde se encuentra.

Para la función de membresía de la variable de salida se utilizó un rango de 0 a 100 para determinar el tamaño de la llama.




Como se puede ver, la combustión reducida se tomó entre piloto y moderado y limitada antes de la combustión alta.

## Resultados obtenidos

**Temperatura Exterior = 20°C**


**Temperatura Interior = 60°C**

## Fuzzification



En la figura se ve como se activan más las reglas de combustión moderada y limitada.


### **Agregación y Salida**




Como podemos ver la centroide quedó en un punto medio entre llama moderada y limitada, por lo tanto podría seguir funcionando así la caldera sin ningún problema.

**Temperatura Exterior = 40°C**  
**Temperatura Interior = 80°C**

### **Fuzzification**




## ***Agregación y Salida***




Teniendo en cuenta que la temperatura interior de la caldera es crítica y la temperatura exterior ya muy grande, lo que debería hacer el sistema es tender a reducir la llama a piloto.

***Temperatura Exterior = 0°C***  
***Temperatura Interior = 30°C***

## ***Fuzzification***





Acá el sistema debería tender a prenderse con una llama limitada ya que las habitaciones están muy frías y el sistema está en reposo.

## Conclusiones

En este trabajo, se ha desarrollado un sistema de automatización para el trabajo de un calderista utilizando el Sistema de Inferencia Difusa de Mamdani. Se ha aplicado la lógica difusa para tomar decisiones sobre el nivel de combustión en función de las temperaturas interiores y exteriores.

El sistema de inferencia difusa de Mamdani permite tomar decisiones de control de manera eficiente y adaptable a las condiciones variables de temperatura interior y exterior.

El enfoque de lógica difusa brinda flexibilidad en la toma de decisiones al considerar rangos lingüísticos como "BAJA", "MEDIA", "ALTA" y "CRITICA" para las temperaturas. Esto permite que el sistema sea más intuitivo y fácilmente adaptable a diferentes situaciones.

Los resultados obtenidos a partir de las simulaciones muestran que el sistema reacciona de manera razonable y segura ante diversas condiciones (tal vez demasiado segura y razonable, se ahonda más en el siguiente párrafo). Por ejemplo, cuando la temperatura interior es crítica y la temperatura exterior es alta, el sistema tiende a reducir la llama a piloto, lo que es una respuesta lógica para evitar el sobrecalentamiento.

Aun así los resultados obtenidos no fueron satisfactorios (a vista de los implementadores) tal vez se podría mejorar ampliando el rango de las variables de entrada y/o implementar en los extremos de las variables funciones sigmoideas para simular mejor los rangos "BAJA" y "ALTA", ya que se utilizaron gaussianas para todo.

**Repositorio:** <https://github.com/facundodelga/TP-IA-sugeno>